

Complemento al Capítulo 3 · Estadística III (3009137)
Universidad Nacional de Colombia, Sede Medellín · 2025

Esta guía complementa la teoría del Capítulo 3 con criterios visuales concretos, heurísticas de diagnóstico, código R comentado y preguntas orientadoras. Su objetivo es convertir el análisis descriptivo de una serie en una práctica sistemática y reproducible.

§	Contenido
1	Flujo de trabajo: las 7 preguntas del analista
2	Determinación del tipo de modelo: aditivo vs. multiplicativo
3	La prueba de amplitud — criterio de la nube de puntos
4	Evaluación de la componente estacional
5	Evaluación de la tendencia
6	Heurísticas visuales rápidas
7	Errores frecuentes y cómo evitarlos
8	Lista de verificación previa al modelo

§ 1. Flujo de trabajo: las 7 preguntas del analista

Antes de escribir una sola línea de código, el analista debe responder en orden estas siete preguntas. Cada respuesta condiciona la siguiente.

P1 ¿Cuántos datos tengo y con qué frecuencia?

Establece el objeto `ts()` con los parámetros `frequency` y `start` correctos. Para datos mensuales `frequency=12`, trimestrales `frequency=4`, anuales `frequency=1`.

P2 ¿Tiene la serie valores negativos o ceros?

Si hay valores ≤ 0 , la transformación logarítmica no aplica directamente. Considere $\log(Y+c)$ con c pequeño, o una transformación Box-Cox. Documente este detalle antes de continuar.

P3 ¿La varianza alrededor de la tendencia crece con el nivel?

Esta es la pregunta central del §2 y §3. Determine si el modelo es aditivo o multiplicativo.

P4 ¿Existe un patrón estacional repetible año tras año?

Use el gráfico por períodos (`monthplot`, `boxplot` por mes/trimestre) para confirmar. Ver §4.

P5 ¿Qué forma tiene la tendencia filtrada?

Grafique la tendencia de `decompose()` en la escala de los datos originales. Ver §5.

P6 ¿Los ciclos son tan pronunciados que distorsionan la tendencia?

Si la tendencia parece una curva sinusoidal compleja, un modelo de regresión pura en `tendencia+estacionalidad` puede ser insuficiente.

P7 ¿Los residuos de la descomposición son ruido blanco o tienen estructura?

Si los residuos muestran autocorrelación, el modelo de regresión clásico necesitará corrección o se deberá considerar un modelo ARIMA.

✓ **Consejo práctico**

Grafique siempre la serie **antes** de cualquier transformación. El ojo humano detecta patrones que ningún test estadístico reportará automáticamente.

§ 2. Determinación del tipo de modelo: aditivo vs. multiplicativo

La pregunta fundamental es: **¿la oscilación estacional crece o se mantiene constante a medida que crece el nivel de la serie?** Si crece, el modelo es multiplicativo; si se mantiene, es aditivo.




Figura 2.1. Izquierda: serie aditiva (oscilaciones de amplitud constante). Derecha: serie multiplicativa (amplitud crece con el nivel).

Tres herramientas diagnósticas complementarias

- Gráfica Y_t vs. t .** Observe si la "banda" de oscilaciones alrededor de la tendencia se ensancha al crecer el nivel. Si la banda es constante → aditivo. Si la banda se ensancha → multiplicativo.
- Comparar Y_t vs. $\log(Y_t)$.** Grafique ambas en la misma escala de tiempo. Si $\log(Y_t)$ muestra una varianza más estable (banda más uniforme) que Y_t , el modelo es multiplicativo. Si $\log(Y_t)$ empeora o no mejora, el modelo es aditivo.
- Residuos de ambas descomposiciones.** Calcule los residuos de `decompose(..., type="additive")$random` y `decompose(..., type="multiplicative")$random`. La descomposición que produzca residuos con varianza más homogénea y sin patrón sistemático es la correcta.

Código R

```
# Código R: comparación de las tres herramientas diagnósticas
serie <- ts(datos, frequency=12, start=c(2000,1))

# (a) Gráfica original
plot(serie, main="Serie original", ylab="Yt")

# (b) Comparar escala original vs. log
par(mfrow=c(1,2))
plot(serie, main="Escala original", ylab="Yt")
plot(log(serie),main="Escala log", ylab="log(Yt)")
par(mfrow=c(1,1))

# (c) Residuos de ambas descomposiciones
par(mfrow=c(1,2))
plot(decompose(serie, type="additive")$random); abline(h=0)
plot(decompose(serie, type="multiplicative")$random); abline(h=1)
par(mfrow=c(1,1))
```

■ Nota

Las tres herramientas deben apuntar en la misma dirección. Si los resultados son contradictorios, prefiera la opción que dé residuos más homogéneos (herramienta c). En la duda, trabaje en escala logarítmica: si los datos son positivos, siempre es válida.

§ 3. La prueba de amplitud — criterio de la nube de puntos

La **prueba de amplitud** (también llamada gráfico de dispersión de amplitud vs. tendencia) es una de las herramientas más intuitivas para decidir entre modelo aditivo y multiplicativo. Consiste en construir una nube de puntos donde cada punto representa un ciclo anual completo.

¿Cómo se construye?

1. Para cada año (o ciclo estacional) k , calcule la **amplitud**: $A_k = \text{máximo de } Y_t \text{ en ese año} - \text{mínimo de } Y_t \text{ en ese año}$.
2. Calcule el **nivel medio** (o de tendencia) de ese año: $T_{\text{■}}_k = \text{promedio de los valores de la tendencia estimada (decompose()$trend) en ese año}$.
3. Construya la nube de puntos: eje $X = T_{\text{■}}_k$, eje $Y = A_k$.
4. Trace una línea de tendencia suave (por ejemplo, con `abline(lm(A~T))`) para visualizar la dirección de la asociación.




Figura 3.1. Izquierda: nube horizontal → amplitud constante → modelo aditivo. Derecha: nube inclinada (tendencia ascendente) → amplitud crece con el nivel → modelo multiplicativo.

Criterios de interpretación de la nube de puntos

Forma de la nube	Interpretación	Modelo sugerido
Puntos dispersos horizontalmente alrededor de una línea plana	La amplitud no varía con el nivel: la "altura" de las oscilaciones estacionales es siempre la misma	Aditivo
Puntos con tendencia ascendente clara (línea de regresión inclinada hacia arriba)	La amplitud crece proporcionalmente con el nivel: cuanto más alta la serie, más grande la oscilación	Multiplicativo

Forma de la nube	Interpretación	Modelo sugerido
Puntos con tendencia descendente (inusual)	La amplitud decrece cuando sube el nivel; puede indicar heterocedasticidad inversa o datos con características especiales	Revisar datos; posible transformación inversa
Nube con dispersión muy alta sin patrón claro	Insuficiente cantidad de ciclos para concluir, o la serie tiene cambios estructurales	Apoyarse en las herramientas (a), (b) y (c) del §2

Regla de oro práctica

Si la línea de regresión lineal ajustada sobre la nube ($A_k \sim T_{\square_k}$) tiene una **pendiente positiva estadísticamente significativa** y el R^2 es razonable (por encima de 0.4), se adopta el modelo multiplicativo. Si la pendiente no difiere significativamente de cero, se adopta el modelo aditivo.

Código R

```
# Código R: prueba de amplitud – nube de puntos

# Paso 1: objeto serie de tiempo
serie <- ts(datos, frequency=12, start=c(2000,1))
n_ciclos <- floor(length(serie) / 12) # número de años completos

# Paso 2: calcular amplitud y nivel medio por año
amplitud <- numeric(n_ciclos)
tendencia_media <- numeric(n_ciclos)
Tt <- decompose(serie, type="additive")$trend

for(k in 1:n_ciclos) {
  idx <- ((k-1)*12 + 1):(k*12)
  amplitud[k] <- max(serie[idx]) - min(serie[idx])
  tendencia_media[k] <- mean(Tt[idx], na.rm=TRUE)
}

# Paso 3: nube de puntos con línea de regresión
plot(tendencia_media, amplitud,
     xlab="Nivel medio de tendencia",
     ylab="Amplitud estacional (max - min)",
     main="Prueba de amplitud",
     pch=19, col="gray30")
abline(lm(amplitud ~ tendencia_media), col="firebrick", lwd=2)

# Paso 4: evaluar pendiente
modelo_amp <- lm(amplitud ~ tendencia_media)
summary(modelo_amp) # observe el p-value de tendencia_media
# p < 0.05 con pendiente > 0 → MULTIPLICATIVO
# p >= 0.05 → ADITIVO
```

■ Atención

Atención con series cortas. Con menos de 6 ciclos completos (6 años para datos mensuales) la nube de puntos tendrá muy pocos puntos y la pendiente puede no ser confiable. En ese caso dé más peso a las herramientas visuales del §2.

✗ Error frecuente

Error frecuente: calcular la amplitud con los datos crudos en lugar de los datos ajustados. Use los valores originales Y_t (no la tendencia) para calcular $\max - \min$, pero use la tendencia filtrada Tt como eje X.

§ 4. Evaluación de la componente estacional

La estacionalidad periódica exacta implica que el mismo patrón se repite con la misma forma e intensidad en cada ciclo. Confirmemos su existencia con tres herramientas complementarias:

Herramienta 1: Gráfico de subseries por período

monthplot() en R (o equivalente por trimestre). Divide la serie en subgrupos por período (enero, febrero, ..., diciembre). Si las medianas por período difieren sistemáticamente, existe estacionalidad.

Código R

```
# Gráfico de subseries mensuales
monthplot(serie)
# O con ggplot2:
library(forecast)
seasonplot(serie, year.labels=TRUE, col=rainbow(20))
```

Herramienta 2: Boxplot por período

Si las medianas de los boxplots varían entre meses/trimestres, la estacionalidad está presente. Además, si los bigotes crecen de izquierda a derecha (meses de mayor nivel tienen más dispersión), esto es otro indicio de modelo multiplicativo.

Código R

```
# Boxplot por mes
boxplot(serie ~ cycle(serie),
names=month.abb,
xlab="Mes", ylab="Valor",
main="Distribución por período")
```

Herramienta 3: Gráfico de los primeros N ciclos superpuestos

Trace cada año como una línea de color diferente sobre el mismo eje de enero a diciembre. Si todas las líneas tienen una forma similar (picos y valles en los mismos meses), la estacionalidad es exacta o casi exacta.

Código R

```
# Serie por años superpuestos
library(forecast)
seasonplot(serie, year.labels=FALSE,
col=gray.colors(length(unique(floor(time(serie))))),
main="Patron estacional por año")
```


✓ Consejo práctico

Si el boxplot por período muestra medianas con pequeñas diferencias pero todas en la misma dirección (todas más altas en verano, por ejemplo), **confíe en la señal visual**: la estacionalidad existe aunque sea débil. Un test formal de Kruskal-Wallis puede respaldar la decisión.

Código R

```
# Test de Kruskal-Wallis para estacionalidad
kruskal.test(as.numeric(serie) ~ as.factor(cycle(serie)))
# H0: la distribución es igual en todos los períodos
# p < 0.05 → se rechaza H0 → hay estacionalidad significativa
```

§ 5. Evaluación de la tendencia

La tendencia es la componente de largo plazo de la serie. El objetivo aquí es identificar qué función matemática del tiempo podría representar la componente T_t extraída por el filtro de descomposición clásica.

Regla crítica: grafique siempre T_t en el mismo rango vertical que los datos originales (argumento `ylim` en R). Una tendencia que parece un polinomio de grado 5 a escala propia puede ser casi una recta cuando se observa en la escala de los datos.

Código R

```
# Tendencia en escala de los datos – caso aditivo
Tt <- decompose(serie, type="additive")$trend
plot(Tt, ylim=c(min(serie, na.rm=TRUE), max(serie, na.rm=TRUE)),
     main="Tendencia filtrada (escala de datos)",
     ylab="Yt")

# Tendencia en escala log – caso multiplicativo
Tt_log <- decompose(log(serie), type="additive")$trend
plot(Tt_log,
     ylim=c(min(log(serie), na.rm=TRUE), max(log(serie), na.rm=TRUE)),
     main="Tendencia filtrada (escala log)",
     ylab="log(Yt)")
```

Patrones de tendencia y funciones candidatas

Patrón visual de T_t	Función candidata (escala de trabajo)	Observación
Línea recta, pendiente constante	$T_t = \beta_0 + \beta_1 t$	El caso más simple. Verifique que no sea una aproximación local de una curva.
Curva suave creciente/decreciente que se aplana	$T_t = \beta_0 + \beta_1 t + \beta_2 t^2$ (parábola) o $T_t = \exp(\beta_0 + \beta_1 t)$ (exponencial)	La parábola puede "dar vuelta" fuera del rango muestral — cuidado con pronósticos largos.
Curva en S (crecimiento logístico)	$T_t = L / (1 + \exp(-k(t-t_0)))$	Típica en adopción de tecnologías o poblaciones con límite de saturación.
Tendencia con quiebres estructurales	Modelos por tramos o variables indicadoras de cambio de nivel	El filtro <code>decompose()</code> muestra "codos". Identifique el período del quiebre.

Patrón visual de T_t	Función candidata (escala de trabajo)	Observación
Tendencia muy irregular o tipo ciclo largo	No aplica modelo de regresión simple	Considere modelos ARIMA o de espacio de estados (ETS).

■ Atención

Si la tendencia tiene muchos ciclos superpuestos (como la serie de desempleo en Francia), el modelo de regresión sobre tendencia+estacionalidad producirá residuos autocorrelacionados. Diagnostique siempre con $acf(\text{residuos})$ antes de dar por válido el modelo.

§ 6. Heurísticas visuales rápidas

Estas reglas son atajos mentales validados por la experiencia práctica. No reemplazan el análisis formal, pero permiten orientar rápidamente el análisis en los primeros minutos de trabajo con una serie nueva.

H1 — El "abanico"	Si en la gráfica de la serie los picos y valles forman un patrón que se ensancha como un abanico de izquierda a derecha, el modelo es multiplicativo. Si el abanico tiene ancho constante, es aditivo.
H2 — La prueba del log visual	Aplique $\log()$ a la serie y vuelva a graficarla. Si el abanico "se cierra" (la serie se ve más simétrica), el modelo original es multiplicativo.
H3 — Regla de los residuos del <code>decompose()</code>	En la descomposición correcta, el panel "random" de <code>plot(decompose(...))</code> debe verse como ruido blanco: sin tendencia, sin patrón estacional visible, con varianza aproximadamente constante.
H4 — Los años atípicos en el boxplot	En el boxplot por mes/trimestre, si un año específico aparece constantemente como valor atípico en todos los meses, puede ser un cambio estructural o un error de datos — investigue antes de modelar.
H5 — Proporción entre componentes	En una serie bien descompuesta, la componente estacional y la tendencia deben explicar la mayor parte de la varianza. Si el componente "random" tiene una varianza similar o mayor que la estacional, el modelo de descomposición clásica puede ser inadecuado.
H6 — Consistencia entre herramientas	Si la gráfica visual dice "aditivo", el test de amplitud dice "multiplicativo" y los residuos no ayudan a decidir, pruebe ambos modelos hasta la etapa de ajuste y compare los criterios de información (AIC/BIC).
H7 — La tendencia en contexto	Una tendencia que parece cuadrática sobre 5 años puede ser lineal sobre 20. Amplíe el rango del eje vertical al rango de los datos y pregúntese ¿cuánto cambia el nivel en el horizonte de pronóstico razonable?

§ 7. Errores frecuentes y cómo evitarlos

Error 1. Graficar la tendencia en su escala propia

Qué ocurre: `decompose()` devuelve la tendencia en la misma escala que la serie. Sin ajustar el `ylim`, el gráfico de la tendencia tiene su propio rango vertical, y lo que parece una curva compleja puede ser casi una recta cuando se ve en la escala de los datos.

Cómo evitarlo: Siempre use `ylim=c(min(serie), max(serie))` al graficar la tendencia.

Error 2. Confundir el residuo del `decompose()` con el error del modelo de regresión

Qué ocurre: El "random" de `decompose()` es la serie original menos la tendencia filtrada menos la estacionalidad estimada. Es un residuo del filtro, no del modelo de regresión que usted va a proponer.

Cómo evitarlo: Analice los residuos del modelo de regresión ajustado, no los del `decompose()`.

Error 3. Decidir el tipo de modelo solo con la serie en escala original

Qué ocurre: Sin ver el log de la serie ni los residuos de ambas descomposiciones, la decisión puede ser incorrecta, especialmente en series con poco contraste entre niveles alto y bajo.

Cómo evitarlo: Use siempre las tres herramientas del §2 antes de decidir.

Error 4. Olvidar que `decompose()` pierde observaciones en los extremos

Qué ocurre: El filtro de medias móviles requiere $m/2$ observaciones en cada extremo (m =periodicidad). Para series mensuales, se pierden los primeros y últimos 6 valores en la tendencia.

Cómo evitarlo: No incluya los NAs del inicio y fin en el análisis de tendencia.

Error 5. Usar la prueba de amplitud con muy pocos ciclos

Qué ocurre: Con 3 o 4 años de datos mensuales, la nube de amplitud solo tiene 3 o 4 puntos: demasiado pocos para establecer una tendencia.

Cómo evitarlo: Con menos de 6 ciclos, base la decisión en las herramientas visuales directas.

Error 6. Asumir estacionalidad sin verificarla

Qué ocurre: No toda serie con frecuencia mensual tiene patrón estacional anual. Una serie de temperatura diaria puede tener estacionalidad semanal, no anual.

Cómo evitarlo: Confirme con `monthplot()`, `boxplot` por período y gráficos de ciclos superpuestos.

§ 8. Lista de verificación previa al modelo

Antes de proponer un modelo de regresión para la serie, confirme que ha completado todos los pasos siguientes. Esta lista puede entregarse como parte del reporte de análisis descriptivo.

Análisis inicial

- He definido correctamente el objeto `ts()` con `frequency` y `start`.
- He graficado la serie en su escala original.
- He verificado que no existen valores negativos o ceros que impidan `log()`.
- He identificado visualmente si existe tendencia y si existe estacionalidad.

Tipo de modelo

- He graficado Y_t vs. t y $\log(Y_t)$ vs. t en la misma escala.
- He comparado los residuos de ambas descomposiciones (aditiva y multiplicativa).
- He construido la prueba de amplitud (nube de puntos) si hay suficientes ciclos.
- He documentado mi decisión (aditivo / multiplicativo) y su justificación.

Componente estacional

- He graficado el `monthplot` o `boxplot` por período.
- He superpuesto los ciclos de distintos años.
- He concluido si hay estacionalidad periódica exacta o casi exacta.

Componente de tendencia

- He graficado $T \blacksquare t$ con `ylim` ajustado al rango de los datos.
- He identificado la forma funcional candidata (lineal, cuadrática, exponencial, etc.).
- He verificado que la tendencia no está dominada por ciclos.

Preparación para el modelo

- Si la serie es multiplicativa, trabajaré con $\log(Y_t)$ (descomposición aditiva del log).
 - He identificado posibles cambios estructurales o valores atípicos.
 - He separado la muestra de ajuste de la muestra de validación cruzada.
-

Documento elaborado como complemento al Capítulo 3: El análisis de series de tiempo · Notas de Clase Estadística III (3009137) · Prof. Nelfi González Álvarez · Universidad Nacional de Colombia, Sede Medellín · 2025