

MANUAL PRÁCTICO

de Análisis de

SERIES DE TIEMPO

Guía práctica para la identificación de tendencia, estacionalidad y componentes aditivas,
multiplicativas y parcialmente multiplicativas · Filtro de Henderson

Estadística · Análisis Cuantitativo · Econometría de Series de Tiempo

Contenido

1.	El modelo de descomposición	3
2.	Identificación de la tendencia	4
3.	Identificación de la estacionalidad	5
4.	Diagnóstico del modelo: ¿aditivo, multiplicativo o parcialmente multiplicativo?	6
5.	La componente parcialmente multiplicativa: detección avanzada	8
6.	El Filtro de Henderson	10
7.	Árbol de decisión	12
8.	Heurística rápida: tabla de diagnóstico	13
9.	Código R de referencia	14

1. El modelo de descomposición

Toda serie de tiempo con estructura puede entenderse como la superposición de tres fuerzas: la **tendencia** (T), que captura la dirección de largo plazo; la **estacionalidad** (S), que refleja patrones recurrentes ligados al calendario; y el **componente irregular** (E), residuo de lo que no explican las dos anteriores. La pregunta central del analista no es si estas componentes existen, sino **cómo se relacionan entre sí**.

Esa relación define el modelo de descomposición y determina la calidad de cualquier ajuste estacional, pronóstico o indicador derivado. Elegir mal el modelo produce residuos con estructura, sesgos sistemáticos en los factores estacionales y pronósticos deficientes.

Modelo	Ecuación	Característica clave
Aditivo	$Y_t = T_t + S_t + E_t$	Amplitud estacional constante; independiente del nivel de la serie
Multiplicativo	$Y_t = T_t \times S_t \times E_t$	Amplitud estacional proporcional al nivel; el error también escala. Equivale al aditivo en $\log(Y)$
Parcialmente Multiplicativo	$Y_t = T_t \times S_t + E_t$	La oscilación estacional crece con T, pero el error irregular permanece de magnitud fija

La distinción entre estos modelos rara vez es obvia a simple vista. Este manual ofrece una secuencia de herramientas visuales y heurísticas concretas para tomar esa decisión con seguridad, sin depender exclusivamente de tests formales.

2. Identificación de la tendencia

La tendencia es la componente más fácil de identificar visualmente, pero también la más fácil de confundir con fluctuaciones de mediano plazo o con ciclos económicos largos. La regla de oro: si el nivel promedio de la serie sube o baja sostenidamente a lo largo de *varios ciclos completos*, hay tendencia.

Tipos de tendencia que debe reconocer

No toda tendencia es una línea recta. Hay tres formas comunes: **lineal** (ascenso o descenso constante); **no lineal** —cuadrática o logarítmica— donde el ritmo de crecimiento cambia (clásico en productos que saturan su mercado); y **estocástica o de paseo aleatorio**, donde parece haber tendencia pero su dirección cambia de forma impredecible. Esta última es la más tramposa: estadísticamente no hay tendencia determinista, pero la serie nunca parece "quieta".




Figura 1. Tres patrones de tendencia comunes. La tendencia no lineal (panel C) es la más fácil de confundir con estacionalidad de largo ciclo si el periodo de observación es corto.

Herramientas de diagnóstico

Visual: Superponga una media móvil de largo periodo (12 meses para series mensuales, 4 trimestres para trimestrales) sobre la serie original. Si esa línea sube o baja de manera consistente en toda la ventana de observación, hay tendencia.

Formal: La prueba ADF (Dickey-Fuller Aumentada) evalúa si la serie tiene raíz unitaria. Si el p-valor es alto (> 0.05), no se rechaza la raíz unitaria y hay evidencia de tendencia estocástica. Complemente siempre con KPSS, que tiene la hipótesis nula opuesta: p-valor bajo rechaza estacionariedad.

Regla práctica: Si la media móvil de 12 meses cambia más de un 15% entre el primer y el último año, casi con certeza hay tendencia. Si oscila alrededor de un nivel estable, presume estacionariedad y valide con ADF.

```
# R: Diagnóstico de tendencia
library(forecast); library(tseries)

# Visual: media móvil 12 meses superpuesta
autoplot(mi_ts) +
  autolayer(ma(mi_ts, order = 12), series = "MA-12", colour = "red")

# Formal: ADF (H0: raíz unitaria / no estacionaria)
adf.test(mi_ts) # p < 0.05 → rechaza raíz unitaria → posible estacionariedad

# KPSS (H0: estacionaria)
kpss.test(mi_ts) # p < 0.05 → rechaza estacionariedad → hay tendencia
# Regla: ADF no rechaza Y KPSS rechaza → tendencia confirmada
```

3. Identificación de la estacionalidad

La estacionalidad es un patrón que se repite con frecuencia fija y conocida: cada 12 meses en series mensuales, cada 4 trimestres en trimestrales. Es fundamentalmente distinta de un ciclo económico, cuya duración varía. El error más frecuente entre los estudiantes es confundir un ciclo de largo plazo con estacionalidad, o no detectar estacionalidad porque la tendencia la enmascara. La solución: **elimine la tendencia antes de buscar estacionalidad**.




Figura 2. Los tres modelos en paralelo. Note cómo en el aditivo los picos y valles tienen altura constante; en el multiplicativo y parcialmente multiplicativo los picos se hacen cada vez más altos conforme avanza la tendencia.

Herramientas de diagnóstico

Gráfico de subseries estacionales: dibuja los valores de cada mes o trimestre por separado. Si la media de enero siempre es mayor que la de julio, hay estacionalidad. Si las medias mensuales son similares, la estacionalidad es débil o inexistente.

Función de autocorrelación (ACF): en una serie mensual con estacionalidad, el ACF mostrará picos significativos en los rezagos 12, 24, 36... La regularidad de esos picos confirma el periodo. Si aparecen picos solo en el primer rezago y decaen suavemente, es señal de tendencia, no de estacionalidad.

Regla práctica: Si el mismo mes o trimestre siempre sube (o siempre baja) respecto a los vecinos, hay estacionalidad. Si el patrón cambia de año en año sin regularidad, lo que parece estacionalidad es en realidad ruido irregular.

```
# R: Diagnóstico de estacionalidad
library(forecast)

# Gráfico de subseries estacionales
ggseasonplot(mi_ts, polar = FALSE) # medias mensuales distintas = estacionalidad

# ACF: buscar picos en múltiplos del período
ggAcf(mi_ts, lag.max = 48) + ggtitle("ACF - picos en lag 12, 24, 36?")

# Descomposición exploratoria rápida
plot(decompose(mi_ts, type = "additive"))
```

4. Diagnóstico del modelo: ¿aditivo, multiplicativo o parcialmente multiplicativo?

Esta es la decisión más importante y la que más confusión genera. Una vez identificadas tendencia y estacionalidad, la pregunta es: ¿la magnitud de la oscilación estacional depende del nivel de la serie? La respuesta define el modelo.

La prueba de la amplitud

Para cada año completo de la serie, calcule el **rango** (máximo menos mínimo dentro de ese año). Luego grafique ese rango contra el nivel promedio de la tendencia en ese mismo año. La pendiente de esa nube de puntos lo dice todo:




Figura 3. Prueba de amplitud. En el modelo aditivo la pendiente es cercana a cero: el rango es constante independientemente del nivel. En el multiplicativo la pendiente es pronunciada y pasa por el origen. En el parcialmente multiplicativo hay pendiente positiva pero el intercepto no es cero, pues el error fijo aporta un componente constante al rango.

La prueba del embudo en los residuos

Un método complementario muy práctico: descomponga siempre primero con el modelo aditivo y grafique los residuos E_t a lo largo del tiempo. La forma que adoptan esos residuos es diagnóstica:




Figura 4. Residuos del modelo aditivo para cada tipo de serie. La "firma" de cada modelo: residuos homocedásticos (aditivo), embudo pronunciado (multiplicativo puro), embudo suave o parcial (parcialmente multiplicativo).

Regla de decisión: residuos homocedásticos → modelo aditivo. Embudo pronunciado → multiplicativo. Si log(Y) estabiliza la amplitud completamente → multiplicativo puro. Si log(Y) solo la reduce parcialmente → parcialmente multiplicativo.

```
# R: Diagnóstico del tipo de modelo
```

```
# Paso 1 – Prueba de amplitud (rango anual vs nivel)
idx <- rep(1:floor(length(mi_ts)/12), each=12)[seq_along(mi_ts)]
annual_range <- tapply(as.vector(mi_ts), idx, function(v) diff(range(v)))
trend_level <- tapply(as.vector(mi_ts), idx, mean)

plot(trend_level, annual_range,
     main = "Amplitud anual vs nivel de tendencia",
     xlab = "Nivel (media anual)", ylab = "Rango (max - min)",
     pch = 19, col = "steelblue")
```

```

lm_amp <- lm(annual_range ~ trend_level)
abline(lm_amp, col = "red", lwd = 2)
summary(lm_amp)  # Pendiente sign. y positiva → amplitud crece

# Paso 2 – Prueba del embudo
res_add <- na.omit(decompose(mi_ts, "additive")$random)
plot(res_add, main = "Residuos – modelo aditivo")
# ¿Embudo? → no es aditivo puro

# Paso 3 – ¿Log estabiliza la amplitud?
res_log <- na.omit(decompose(log(mi_ts), "additive")$random)
plot(exp(res_log), main = "Residuos – log(Y) aditivo")
# Homocedásticos → multiplicativo puro
# Embudo leve persiste → parcialmente multiplicativo

```

5. La componente parcialmente multiplicativa: detección avanzada

El modelo $Y_t = T_t \times S_t + E_t$ es el más frecuente en la práctica económica y el más difícil de diagnosticar. Su firma específica: la **amplitud estacional crece con el nivel de la serie**, pero el **ruido irregular permanece de magnitud aproximadamente constante**. Esto es lo que lo distingue del multiplicativo puro, donde todo —incluyendo el error— escala proporcionalmente con la tendencia.

Piénselo así: en las ventas de una empresa que crece, enero siempre vende más y agosto siempre menos, y esa diferencia se hace más grande conforme la empresa crece (eso es $T \times S$). Pero los "sobresaltos" imprevistos —una huelga, una ola de frío, un fallo logístico— siguen siendo del mismo orden de magnitud independientemente del tamaño de la empresa (eso es el $+ E$ constante).

Los cuatro diagnósticos visuales




Figura 5. Los cuatro diagnósticos para la componente parcialmente multiplicativa. (1) Los picos de la serie crecen con la tendencia. (2) La nube de rango anual vs nivel tiene pendiente positiva clara. (3) Los residuos del modelo aditivo muestran un embudo suave —no pronunciado—. (4) $\log(Y)$ reduce la variación de amplitud pero no la elimina.

Las tres manifestaciones prácticas

Manifestación	Descripción	Señal diagnóstica clave
Tendencia lineal	La oscilación estacional crece linealmente con T	Rango anual $\propto$ año; pendiente significativa en prueba de amplitud
Tendencia cuadrática + error pesado	Crecimiento de amplitud acelerado; el error tiene colas pesadas (Laplace)	Embudo con outliers pronunciados; log mejora los residuos pero no los estabiliza del todo
Patrón estacional fijo irregular	El patrón se repite cada año, pero el rango varía irregularmente entre años	Subseries plot con alta varianza interanual; coeficiente de variación no constante por mes

Criterio de selección definitivo: Si la prueba de amplitud muestra pendiente positiva Y los residuos del modelo multiplicativo (log-transformado) aún presentan heterocedasticidad leve, el modelo parcialmente multiplicativo es el más apropiado. En X-13ARIMA-SEATS esto se maneja especificando `transform.function="none"` con un modelo de error aditivo y componente estacional multiplicativa.

```
# R: Confirmar y ajustar modelo parcialmente multiplicativo
library(seasonal)

# Confirmar: pendiente significativa en prueba de amplitud
# (ver código sección 4)

# Ajuste con X-13: componente estacional multiplicativa, error aditivo
m_pm <- seas(mi_ts,
             transform.function = "none",    # No log-transform
             regression.aictest  = NULL,
             outlier.types      = "all")
summary(m_pm)
plot(m_pm)

# Comparar AIC del modelo aditivo, multiplicativo y parcialmente mult.
m_add <- seas(mi_ts, transform.function = "none")
m_mul <- seas(mi_ts, transform.function = "log")
AIC(m_add); AIC(m_mul); AIC(m_pm)    # Menor AIC = mejor ajuste
```

6. El Filtro de Henderson

El filtro de Henderson es una **media móvil asimétrica de mínima curvatura**, diseñada por Robert Henderson en 1916 para suavizar tablas actuariales. Hoy es el suavizador de tendencia-ciclo estándar en todos los sistemas de ajuste estacional oficiales: X-12-ARIMA, X-13ARIMA-SEATS y TRAMO-SEATS. Los institutos nacionales de estadística de todo el mundo lo usan como referencia.

Su ventaja sobre una simple media móvil es que pondera más los valores centrales y menos los extremos, preservando mejor los puntos de inflexión de la tendencia. A costa de eso, es más sensible al ruido si se elige demasiado corto.

¿Cuándo usarlo?

Use el filtro de Henderson para extraer la componente de tendencia-ciclo **de una serie ya ajustada estacionalmente**. Es el paso que sigue *después* de eliminar la estacionalidad, nunca antes. Aplicarlo directamente sobre la serie original produce resultados confusos porque mezcla tendencia y estacionalidad en la misma señal suavizada.




Figura 6. Efecto de la longitud del filtro de Henderson sobre la serie ajustada estacionalmente. Panel izquierdo: filtros de 5, 13 y 23 términos. Panel derecho: el compromiso entre suavidad y pérdida de observaciones en los extremos. La zona verde (11–17 términos) es el rango óptimo para la mayoría de series mensuales.

¿Cómo elegir la longitud?

La longitud óptima depende del **ratio I/C** (Irregular/Ciclo-Tendencia): cuánto ruido hay en la serie ajustada relativo a la señal de tendencia. X-13ARIMA-SEATS lo calcula automáticamente. Para cálculo manual, es el cociente entre la desviación estándar de la componente irregular y la desviación estándar de las primeras diferencias de la tendencia-ciclo.

Ratio I/C	Longitud recomendada	Interpretación práctica
< 1.0	5 o 7 términos	Serie poco ruidosa; filtro corto preserva variaciones reales de la tendencia
1.0 – 3.5	9 o 13 términos	Caso más común en series económicas mensuales (empleo, ventas, producción)
> 3.5	17 o 23 términos	Serie muy ruidosa; filtro largo necesario para distinguir tendencia del ruido

Consejo práctico: Si no tiene acceso a X-13, empiece con Henderson 13 para series mensuales y ajuste según los resultados. Si la tendencia resultante es demasiado "nerviosa" (zigzaguea), suba a 17 o 23. Si es demasiado suave y pierde puntos de giro evidentes, baje a 9 o 11.

```

# R: Filtro de Henderson manual + elección de longitud
henderson_weights <- function(m) {
  n <- (m-1)/2; k <- -n:n
  w <- (1-(k/(n+1))^2) * (1-(k/(n+2))^2) * (1-(k/(n+3))^2)
  w / sum(w)
}
apply_henderson <- function(x, m = 13) {
  w <- henderson_weights(m); n <- length(w) %% 2
  y <- rep(NA_real_, length(x))
  for (i in (n+1):(length(x)-n)) y[i] <- sum(w * x[(i-n):(i+n)])
  ts(y, start = start(x), frequency = frequency(x))
}

# Calcular I/C ratio para elegir longitud
library(seasonal)
m_seas <- seas(mi_ts)
sa <- seasadj(m_seas) # Serie ajustada estacionalmente
tc13 <- apply_henderson(as.vector(sa), 13) # Tendencia-ciclo con H-13
irreg <- as.vector(sa) - tc13
ic_ratio <- sd(na.omit(irreg)) / sd(na.omit(diff(na.omit(tc13))))
cat("I/C ratio:", round(ic_ratio, 2), "
")
# < 1 → H-5/7 | 1-3.5 → H-9/13 | > 3.5 → H-17/23

# Comparar visualmente tres longitudes
tc5 <- apply_henderson(as.vector(sa), 5)
tc23 <- apply_henderson(as.vector(sa), 23)
ts.plot(sa, tc5, tc13, tc23,
  col = c("grey70", "blue", "darkgreen", "red"), lwd = c(1,2,2,2))
legend("topleft", c("SA", "H-5", "H-13", "H-23"),
  col=c("grey70", "blue", "darkgreen", "red"), lwd=2)

```

7. Árbol de decisión

El siguiente diagrama condensa el proceso completo de identificación. Úselo como guía de navegación la primera vez que enfrenta una serie desconocida. La práctica convertirá estas preguntas en un reflejo casi automático.

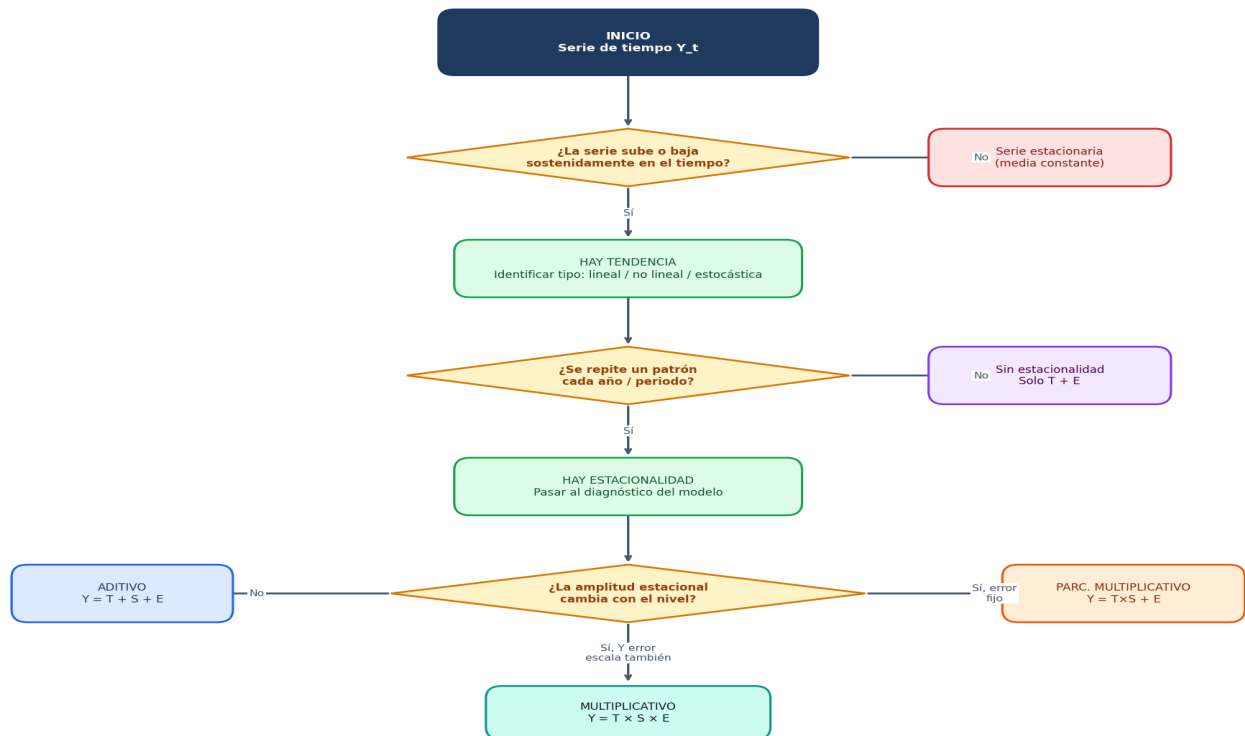


Figura 7. Árbol de decisión para la identificación de componentes. El proceso es secuencial: primero tendencia, luego estacionalidad, finalmente el tipo de modelo. Cada rama incluye la acción recomendada.

8. Heurística rápida: tabla de diagnóstico

Use esta tabla como lista de chequeo. Para cada pregunta, aplique la herramienta indicada y contraste la señal que obtiene con las columnas "Sí" y "No".

Pregunta	Herramienta	Señal → Sí	Señal → NO
¿Hay tendencia?	MA de largo periodo	MA sube o baja de forma consistente	MA oscila alrededor de una media estable
	Prueba ADF	$p > 0.05$ (no rechaza raíz unitaria)	$p < 0.05$ (rechaza raíz unitaria)
	Prueba KPSS	$p < 0.05$ (rechaza estacionariedad)	$p > 0.05$ (no rechaza estacionariedad)
¿Hay estacionalidad?	Subseries plot	Medias mensuales/trimestrales claramente distintas	Medias similares entre períodos del año
	ACF	Picos significativos en lag 12, 24, 36...	Sin picos en múltiplos del período
¿Qué modelo?	Rango anual vs nivel	Pendiente $\approx 0 \rightarrow$ ADITIVO	Pendiente $> 0 \rightarrow$ Multiplicativo o P.M.
	Residuos decompose(add.)	Homocedásticos $\rightarrow$ ADITIVO	Embudo $\rightarrow$ Multiplicativo o P.M.
	$\log(Y)$: ¿amplitud estable?	Sí $\rightarrow$ MULTIPLICATIVO PURO	Solo reducción parcial $\rightarrow$ PARC. MULT.
¿Longitud Henderson?	Ratio I/C	$I/C < 1 \rightarrow$ H-5/7	$I/C > 3.5 \rightarrow$ H-17/23 I/C 1-3.5 $\rightarrow$ H-9/13

